

Tehnici de Optimizare

- Seminar 4 -

Probleme de programare neliniară. Algoritmi.

1 Probleme de programare convexă

Modelul general al problemelor de programare neliniara se rezuma la:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} f(x) \\ \text{s.l. } g_i(x) = 0, \quad \forall i = 1, \dots, m \\ h_i(x) \leq 0, \quad \forall i = 1, \dots, p. \end{aligned} \quad (1)$$

unde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ reprezinta funcția obiectiv, g_i, h_i funcțiile asociate constrângerilor de egalitate, respectiv inegalitate. În particular, problema:

$$\begin{aligned} f^* = \min_{x \in \mathbb{R}^n} f(x) \\ \text{s.l. } A_i x = b_i, \quad \forall i = 1, \dots, m \\ C_i x \leq d_i, \quad \forall i = 1, \dots, q. \\ h_i(x) \leq 0, \quad \forall i = q + 1, \dots, p. \end{aligned} \quad (2)$$

este convexă dacă $f, \{h_i\}_{1 \leq i \leq p}$ sunt funcții convexe.

Funcția Lagrangian:

$$\begin{aligned} L(x, \lambda, \mu) &= f(x) + \lambda^T g(x) + \mu^T h(x) \\ L(x, \lambda, \mu) &= f(x) + \lambda^T (Ax - b) + \mu^T h(x) = f(x) + \sum_i \lambda_i (A_i x - b_i) + \sum_i \mu_i h_i(x) \end{aligned}$$

Funcția Duală:

$$\phi(\lambda, \mu) = \min_x L(x, \lambda, \mu)$$

Problema duală:

$$\phi^* = \max_{\mu \geq 0, \lambda} \phi(\lambda, \mu)$$

Condițiile suficiente de optimalitate Kuhn-Tucker:

Dacă f, h convexe și $f^* = \phi^*$ atunci x^* soluție pentru (3) dacă și numai dacă:

$$\begin{aligned} \nabla_x L(x^*, \lambda^*, \mu^*) &= 0 && \text{Optimalitate} \\ Ax^* + b &= 0, h(x^*) \leq 0 && \mu^* \geq 0 && \text{Fezabilitate} \\ \mu_i^* h_i(x^*) &= 0, && && \text{Complementaritate} \end{aligned}$$

Pentru a avea **optimalitate tare** $f^* = \phi^*$ este suficientă condiția Slater:

$$\exists x : h(x) < 0, \quad Ax = b$$

Mai general, condiția de mai sus se poate relaxa: fie h_i , unde $1 \leq i \leq q$, funcții afine, iar restul neliniare, atunci

$$\exists x : h_i(x) \leq 0 \quad [1 \leq i \leq q] \quad h_i(x) < 0, \quad [q+1 \leq i \leq p] \quad Ax = b$$

Multiplicatorii Lagrange reprezintă soluția problemei duale:

$$(\lambda^*, \mu^*) = \arg \max_{\mu \geq 0, \lambda} \phi(\lambda, \mu)$$

Concluzie: rezolvând problema duală, i.e. calcularea (λ^*, μ^*) , sub presupunerile condițiilor Kuhn-Tucker, se recuperează soluția primală x^* din rezolvarea sistemului:

$$\nabla_x L(x, \lambda^*, \mu^*) = 0.$$

Exercitii: Deduceți problema duală și condiții le de optimalitate KT pentru următoarele probleme primale:

$$1. \min_{x \in \mathbb{R}^2} 2x_1^2 + 3x_2^2 \quad \text{s.t.} \quad x_1 + x_2 \leq 1$$

Funcția Lagrangian:

$$L(x, \mu) = 2x_1^2 + 3x_2^2 + \mu(x_1 + x_2 - 1) = \frac{1}{2}x^T \begin{bmatrix} 4 & 0 \\ 0 & 6 \end{bmatrix} x + \mu[1 \quad 1]x - \mu$$

$$\min_x L(x, \mu) = L(x^*(\mu), \mu) \Rightarrow \nabla_x L(x^*(\mu), \mu) = 0$$

$$\begin{bmatrix} 4x_1(\mu) + \mu \\ 6x_2(\mu) + \mu \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \Rightarrow x^*(\mu) = \begin{bmatrix} -\mu/4 \\ -\mu/6 \end{bmatrix} = -\mu \begin{bmatrix} 1/4 \\ 1/6 \end{bmatrix}$$

Funcția Duală:

$$\phi(\mu) = \min_x L(x, \mu) = L(x^*(\mu), \mu) = -\mu^2/6 - \mu$$

$$\max_{\mu \geq 0} -\mu^2/6 - \mu \quad \mu^* = 0 \Rightarrow x^*(\mu^*) = x^* = 0$$

$$\begin{aligned} \begin{bmatrix} 4x_1^* + \mu^* \\ 6x_2^* + \mu^* \end{bmatrix} &= \begin{bmatrix} 0 \\ 0 \end{bmatrix} && \text{Optimalitate} \\ x_1^* + x_2^* &\leq 1 \quad \mu^* \geq 0 && \text{Fezabilitate} \\ \mu^*(x_1^* + x_2^* - 1) &= 0, && \text{Complementaritate} \end{aligned}$$

$$Pp. \quad \mu^* > 0 \Rightarrow x_1^* = -\mu^*/4, x_2^* = -\mu^*/6 \Rightarrow \mu^* = -12/5 (\text{contradicție!})$$

$$\mu^* = 0 \Rightarrow x^* = 0$$

2. $\min_{x \in \mathbb{R}^2} x_1 - x_2$ s.l. $x_1 + x_2 = 1, -x_1 \leq 0, -x_2 \leq 0$

Funcția Lagrangian:

$$\begin{aligned} L(x, \lambda, \mu) &= x_1 - x_2 + \lambda(x_1 + x_2 - 1) + \mu_1(-x_1) + \mu_2(-x_2) \\ &= x_1(\lambda - \mu_1 + 1) + x_2(\lambda - \mu_2 - 1) - \lambda \end{aligned}$$

$$\phi(\lambda, \mu) = \begin{cases} -\infty, & \text{dacă } \mu_1 \neq \lambda + 1, \mu_2 \neq \lambda - 1 \\ -\lambda & \text{dacă } \mu_1 = \lambda + 1, \mu_2 = \lambda - 1 \end{cases}$$

Problema duală:

$$\max_{\lambda, \mu \geq 0} -\lambda \text{ s.l. } \mu_1 = \lambda + 1, \mu_2 = \lambda - 1$$

$$x_1^* - x_2^* = -\lambda^*$$

$$x_1^* + x_2^* = 1, x^* \geq 0 \quad \mu_1^* = \lambda^* + 1, \mu_2^* = \lambda^* - 1, \mu^* \geq 0$$

$$\mu_1^* x_1^* = 0, \mu_2^* x_2^* = 0,$$

Optimalitate

Fezabilitate

Complementaritate

3. Program liniar: $\min_x c^T x$ s.l. $Ax = b, x \geq 0$

4. $\min_x c^T x$ s.l. $\|x\|^2 \leq 1$

5. CMMP: $\min_x \frac{1}{2} x^T x$ s.l. $Ax = b, A \in \mathbb{R}^{m \times n}$

Presupunere: Există x : a.i. $Ax = b$

Funcția Lagrangian:

$$L(x, \lambda) = \frac{1}{2} x^T x + \sum_i \lambda_i (A_i x - b_i) = \frac{1}{2} \|x\|^2 + \lambda^T (Ax - b)$$

Funcția duală:

$$\phi(\lambda) = \min_x \frac{1}{2} \|x\|^2 + \lambda^T (Ax - b)$$

$$x^*(\lambda) = -A^T \lambda$$

$$\max_{\lambda} \phi(\lambda) = -\frac{1}{2} \|A^T \lambda\|^2 - \lambda^T b \quad Hess = -AA^T \preceq 0 (\phi \text{ concava})$$

$$AA^T \lambda^* = -b \Rightarrow \lambda^* = -(AA^T)^{-1} b \quad (AA^T \text{ full-rank}) \Rightarrow x^* = A^T (AA^T)^{-1} b$$

Sistemul Kuhn-Tucker: $x^* = -A^T \lambda^*$ (Optimalitate), $Ax^* = b$ (Fezabilitate)

6. Program patratic: $\min_x \frac{1}{2} x^T H x + q^T x$ s.l. $Ax = b$

Sistemul Kuhn-Tucker:

$$\begin{aligned} Hx + q + A^T \lambda &= 0, [n \text{ ecuatii}] \\ Ax &= b [m \text{ ecuatii}] \end{aligned}$$

Daca $H \succ 0$ atunci

$$x^* = -H^{-1}(q + A^T \lambda^*) \Rightarrow AH^{-1}(A^T \lambda^* + q) = -b \Rightarrow \lambda^* = -AH^{-1}A^T(b + AH^{-1}q)$$

7. $\pi_H(x^0) = \arg \min_x \frac{1}{2} \|x - x^0\|^2$ s.l. $a^T x = b$

$$L(x, \lambda) = \frac{1}{2} \|x - x^0\|^2 + \lambda(a^T x - b)$$

Sistemul Kuhn-Tucker:

$$\begin{aligned} x^* &= x^0 - \lambda^* a = 0, [Optimalitate] \\ a^T x^* &= b [Fezabilitate] \end{aligned}$$

$$a^T(x^0 - \lambda^* a) = b \Rightarrow \lambda^* = \frac{a^T x^0 - b}{\|a\|^2} \Rightarrow \pi_H(x^0) = x^0 - \frac{a^T x^0 - b}{\|a\|^2} a$$

2 Algoritmi

2.1 Metoda Gradient Proiectat cu Liniarizare

$$\begin{aligned} x^{k+1} &= \arg \min_{x \in \mathbb{R}^n} f(x^k) + \nabla f(x^k)^T (x - x^k) + \frac{1}{2\alpha} \|x - x^k\|^2 \\ \text{s.l. } A_i x &= b_i, \quad \forall i = 1, \dots, m \\ h_i(x) &\approx h_i(x^k) + \nabla h_i(x^k)^T (x - x^k) \leq 0, \quad \forall i = 1, \dots, p. \end{aligned} \tag{3}$$

Presupunem ca $A = 0$.

Metoda Gradient Proiectat cu Liniarizare (x^0, ϵ)

Initializeaza $k = 0$.

Cat timp *criteriu_stop* :

1. Calculeaza $\nabla f(x^k), \nabla h_1(x^k), \dots, \nabla h_p(x^k)$
2. Actualizeaza:

$$x^{k+1} = \pi_{Q_k}(x^k - \alpha_k \nabla f(x^k)), \quad Q_k = \{x : Ax = b, h_i(x^k) + \nabla h_i(x^k)^T(x - x^k) \leq 0, \quad \forall i = 1, \dots, p\}$$

3. Set $k := k + 1$.
-

Criteriu de stop: $\|x^{k+1} - x^k\| \leq \epsilon$

Aratati forma explicita a iteratiei MGPL pentru problema:

$$\min_{x \in \mathbb{R}^2} \frac{1}{2} x^T H x + q^T x \text{ s.l. } \|x\|^2 \leq 1$$

Calculati prima iteratie cu pas $\frac{1}{L_f}$, pornind din $x^0 = [0 \ 1]^T$ pentru $H = I_2, q = [11]^T$.

$$y = x^0 - \frac{1}{L} \nabla f(x^0) = x^0 - \nabla f(x^0) = x^0 - (Hx^0 + q) = -q$$

$$h_1(x) = \|x\|^2 - 1, \nabla h_1(x^0) = 2x^0, h_1(x^0) = 0$$

$$\begin{aligned} Q_0 &= \{x : (x^0)^T(x - x^0) = x_1^0(x_1 - x_1^0) + x_2^0(x_2 - x_2^0) \leq 0\} \\ &= \{x : x_2 \leq 1\} \end{aligned}$$

$$x^1 = \pi_{Q_0}(y) = [-1 \ -1]^T.$$

2.2 Algoritmul dual

$$\max_{\lambda, \mu \geq 0} \phi(\lambda, \mu) = - \min_{\lambda, \mu \geq 0} -\phi(\lambda, \mu)$$

Metoda Gradient Proiectat Dual (λ^0, ϵ)

Initializeaza $k = 0$.

Cat timp *criteriu_stop* :

1. Calculeaza $\nabla_\lambda \phi(\lambda^k, \mu^k), \nabla_\mu \phi(\lambda^k, \mu^k)$
2. Actualizeaza:

$$\begin{aligned} \lambda^{k+1} &= \lambda^k + \alpha_k \nabla_\lambda \phi(\lambda^k, \mu^k) \\ \mu^{k+1} &= \max(0, \mu^k + \alpha_k \nabla_\mu \phi(\lambda^k, \mu^k)) \end{aligned}$$

3. Set $k := k + 1$.
-

Criteriu de stop: $\|\lambda^{k+1} - \lambda^k\| \leq \epsilon$

$$\nabla_x L(\hat{x}^*, \lambda_f, \mu_f) = 0 \quad [\hat{x}^* \text{ aproape } - \text{optim}]$$

Aratati forma explicita a iteratiei MGPL pentru problema:

$$\min_{x \in \mathbb{R}^n} \frac{1}{2} x^T H x + q^T x \text{ s.l. } \|x\|^2 \leq 1$$

Calculati prima iteratie cu pas $\alpha = 1$, pornind din $\mu^0 = 1$ pentru $H = I_2, q = [1 \ 1]^T$.

$$\phi(\mu) = \min_x \frac{1}{2} x^T H x + q^T x + \mu(\|x\|^2 - 1) = -\frac{1}{1 + 2\mu} - \mu$$

$$(H + 2\mu I_2)x + q = 0 \Rightarrow x(\mu) = -(H + 2\mu I_2)^{-1}q = -\frac{1}{1 + 2\mu}q$$

$$\mu^{k+1} = \mu^k - \alpha_k(1 + 2/(1 + 2\mu^k)^2)$$